UNIVERSIDAD DEL ZULIA
FACULTAD EXPERIMENTAL DE CIENCIAS
DIVISIÓN DE ESTUDIOS PARA GRADUADOS
PROGRAMA DE MAESTRÍA EN TECNOLOGÍA DE INFORMACIÓN Y COMUNICACIÓN

Computación Acelerada para IA

Elaborado por: Dra. Yaskelly Yedra

Aprobación Comité Académico
Programa de Educación Continua:

Aprobación Consejo Técnico
División de Estudios para Graduados:

Aprobación Consejo de Facultad:

Aprobación Consejo Central de
Estudios para Graduados:

Aprobación Consejo Universitario:

Enero, 2026

1. IDENTIFICACIÓN DEL CURSO

NOMBRE: Computación Acelerada para Inteligencia Artificial

CÓDIGO: **UNIDADES CRÉDITO:** 2

COORDINADOR: Yaskelly Yedra

PROFESOR(ES): Yaskelly Yedra

PROGRAMA: Maestría en Tecnología de Información y Comunicación

Nº DE HORAS SEMANALES: 8 **Teóricas:** 4 **Prácticas:** 4

DURACIÓN CALCULADA EN HORAS: 32

HORARIO: Martes 8:00 pm a 10:00 pm y Sábados 10:00 am a 12:00 m
Lunes y Jueves de 8:00 pm a 10:00 pm

PRERREQUISITOS: Ninguno

DIRIGIDO A: Estudiantes de la Maestría en Tecnología de Información y Comunicación. Ingenieros o Licenciados en Computación, Sistemas, Informática o carrera afín.

2. JUSTIFICACIÓN

La acelerada evolución de la Inteligencia Artificial ha transformado la forma en que se diseñan, entrenan y despliegan modelos capaces de resolver problemas cada vez más complejos. El crecimiento exponencial del tamaño de los modelos de aprendizaje profundo, los Modelos de Lenguaje de Gran Escala (LLMs), los sistemas de Recuperación Aumentada por Generación (RAG) y las arquitecturas basadas en agentes inteligentes ha incrementado significativamente los requerimientos computacionales, haciendo indispensable el uso de infraestructuras especializadas que permitan ejecutar estos sistemas de manera eficiente, escalable y económicamente sostenible.

En este contexto, la asignatura Computación Acelerada para Inteligencia Artificial de la Maestría en Tecnología de Información y Comunicación de la Universidad del Zulia se plantea como un espacio de formación avanzada orientado al diseño, implementación, optimización y escalabilidad de aplicaciones modernas de Inteligencia Artificial mediante la integración de infraestructura especializada, frameworks de aprendizaje profundo, compiladores optimizados y plataformas cloud de alto rendimiento.

La asignatura introduce al participante en los principios de la Ingeniería de Infraestructura para Inteligencia Artificial, entendida como la disciplina que integra hardware acelerado, software especializado y plataformas de ejecución para diseñar soluciones de IA capaces de entrenarse, desplegarse y operar eficientemente en entornos reales de investigación e industria. Para ello, se estudian arquitecturas aceleradas basadas en GPUs y TPUs, frameworks como JAX, TensorFlow y PyTorch/XLA, compilación mediante XLA, entrenamiento distribuido, servicios administrados como Vertex AI, plataformas de supercomputación para IA como AI Hypercomputer y metodologías para la evaluación del rendimiento, la optimización de costos y la escalabilidad de modelos y sistemas inteligentes.

La asignatura continúa la evolución del proyecto integrador desarrollado en las asignaturas previas de la Maestría, permitiendo transformar una aplicación o

plataforma inteligente en una solución preparada para escenarios de producción. Durante su desarrollo, los participantes optimizarán progresivamente el entrenamiento, la inferencia y la escalabilidad de modelos y sistemas inteligentes, incorporando técnicas de compilación acelerada, procesamiento paralelo, entrenamiento distribuido, despliegue sobre infraestructura especializada y evaluación del desempeño. De esta manera, se reproduce un proceso de ingeniería similar al utilizado actualmente por organizaciones e instituciones de investigación que desarrollan soluciones avanzadas basadas en Inteligencia Artificial.

Asimismo, esta asignatura constituye una de las tres líneas de profundización de la Maestría en Tecnología de Información y Comunicación. Mientras Machine Learning se orienta al diseño, entrenamiento y evaluación de modelos capaces de aprender a partir de los datos, y Sistemas Multiagente aborda el diseño de arquitecturas colaborativas para agentes inteligentes y mecanismos de coordinación, Computación Acelerada para Inteligencia Artificial proporciona los fundamentos necesarios para ejecutar, optimizar y escalar dichos modelos y sistemas mediante el uso de infraestructura de alto rendimiento, plataformas especializadas y arquitecturas de computación acelerada.

En conjunto, estas tres líneas de profundización permiten al participante desarrollar una visión integral de la Inteligencia Artificial moderna, abordando tres dimensiones complementarias: el aprendizaje de modelos, el diseño de sistemas inteligentes colaborativos y la infraestructura necesaria para entrenarlos, desplegarlos y operarlos de forma eficiente a gran escala. Este enfoque fortalece las competencias profesionales requeridas para afrontar los desafíos tecnológicos de la próxima generación de sistemas inteligentes, integrando fundamentos científicos con prácticas de ingeniería aplicadas al desarrollo de soluciones de Inteligencia Artificial de alto rendimiento.

3. OBJETIVOS

3.1. OBJETIVO GENERALES

Diseñar, implementar y optimizar aplicaciones modernas de Inteligencia Artificial mediante el uso de técnicas de computación acelerada e infraestructura especializada, aplicando un enfoque incremental basado en proyectos para desarrollar soluciones eficientes, escalables y preparadas para escenarios de producción.

3.2. OBJETIVOS ESPECÍFICO(S)

3.2.1.- Comprender y utilizar arquitecturas de computación acelerada, frameworks especializados y compiladores optimizados para ejecutar modelos de Inteligencia Artificial sobre infraestructura de alto rendimiento.
3.2.2.- Optimizar el entrenamiento y la inferencia de modelos y sistemas inteligentes mediante técnicas de procesamiento paralelo, compilación acelerada y entrenamiento distribuido.
3.2.3.- Diseñar estrategias de despliegue, escalabilidad y evaluación del rendimiento de aplicaciones de Inteligencia Artificial utilizando plataformas cloud e infraestructura especializada para escenarios de producción.

4. CONTENIDO PROGRAMÁTICO

Tema 1: Fundamentos de la Computación Acelerada para Inteligencia Artificial
Introducción a la Computación Acelerada para Inteligencia Artificial. Ingeniería de Infraestructura para Inteligencia Artificial. Arquitecturas de procesamiento: CPU, GPU y TPU. Computación heterogénea. Introducción a AI Hypercomputer. Frameworks para Inteligencia Artificial: TensorFlow, PyTorch y JAX. Compilación acelerada mediante XLA. Entornos de desarrollo para Inteligencia Artificial. Selección de infraestructura para aplicaciones modernas de Inteligencia Artificial.

Tema 2: Optimización del Entrenamiento e Inferencia de Modelos de Inteligencia Artificial

Entrenamiento acelerado de modelos de Inteligencia Artificial. Procesamiento paralelo. Técnicas de entrenamiento distribuido. Mixed Precision. Optimización mediante XLA. Optimización de inferencia. Profiling y análisis del rendimiento. Identificación de cuellos de botella. Benchmarking de modelos. Estrategias para mejorar el rendimiento y la eficiencia computacional de aplicaciones de Inteligencia Artificial.

Tema 3: Escalabilidad e Infraestructura para Aplicaciones Modernas de Inteligencia Artificial

Infraestructura cloud para Inteligencia Artificial. Plataformas administradas para Inteligencia Artificial. AI Hypercomputer. Despliegue de modelos para producción. Model Serving y Endpoints. Autoescalado de aplicaciones inteligentes. Evaluación del rendimiento. Observabilidad de sistemas de Inteligencia Artificial. Optimización de costos computacionales. Buenas prácticas para el diseño, despliegue y operación de aplicaciones modernas de Inteligencia Artificial.

5. PLAN DE EVALUACIÓN

Descripción	% Evaluación	Fecha
Tema 1: Sprint técnico 1	15%	10/11/26
Tema 2: Sprint técnico 2	15%	17/11/26
Tema 3: Sprint técnico 3	15%	24/11/26
Proyecto final	50%	01/12/26
Participación, asistencia y documentación	5%	siempre

6. ESTRATEGIAS DE APRENDIZAJE

Sesiones de clases. Discusión de artículos científicos o arbitrados. Elaboración de laboratorios en asíncronos para la solución de problemas. Realización de un proyecto final.

7. RECURSOS INSTRUCCIONALES

Presentaciones, pizarrón electrónico, artículos científicos, casos de estudio, computador, herramientas de software en la nube, entre otros.

8. BIBLIOGRAFÍA y RECURSOS DE CONSULTA

Fundamentos de Inteligencia Artificial

- Russell, S., & Norvig, P. Artificial Intelligence: A Modern Approach *(4th* Edition). Pearson. https://aima.cs.berkeley.edu/

Computación Acelerada para Inteligencia Artificial

- Google Cloud. AI Hypercomputer Documentation. https://cloud.google.com/ai-hypercomputer
- Google Cloud. Cloud TPU Documentation. https://cloud.google.com/tpu/docs
- NVIDIA. CUDA C++ Programming Guide. https://docs.nvidia.com/cuda/
- NVIDIA. NVIDIA Deep Learning Performance Guide. https://docs.nvidia.com/deeplearning/performance/

Frameworks para Deep Learning

- TensorFlow Documentation. https://www.tensorflow.org/
- PyTorch Documentation. https://pytorch.org/docs/
- JAX Documentation. https://docs.jax.dev/
- PyTorch/XLA Documentation. https://docs.pytorch.org/xla/
- OpenXLA Project Documentation. https://openxla.org/

Optimización del Entrenamiento e Inferencia

- Google DeepMind. JAX for AI Workloads. https://docs.jax.dev/
- OpenXLA Project. https://openxla.org/
- NVIDIA. TensorRT Documentation. https://docs.nvidia.com/deeplearning/tensorrt/
- Google Cloud. Cloud TPU Performance Guide. https://cloud.google.com/tpu/docs/performance-guide

Sistemas Distribuidos y Escalabilidad

- Dean, J., & Ghemawat, S. MapReduce: Simplified Data Processing on Large Clusters. https://research.google/pubs/pub62/
- Google Cloud Architecture Center. https://cloud.google.com/architecture
- Google Cloud. Best Practices for AI Infrastructure. https://cloud.google.com/architecture/ai-ml

Herramientas para Desarrollo y Experimentación

- Google Colab. https://colab.research.google.com/
- GitHub. https://github.com/
- Python. https://www.python.org/
- Docker Documentation. https://docs.docker.com/

Lecturas Complementarias

- Jouppi, N. P., et al. (2017). In-Datacenter Performance Analysis of a Tensor Processing Unit.https://arxiv.org/abs/1704.04760
- Jouppi, N. P., et al. (2021). Ten Lessons From Three Generations Shaped Google's TPUv4i. https://arxiv.org/
- Google Research Publications. https://research.google/pubs/
- NVIDIA Research. https://research.nvidia.com/
- Google DeepMind Publications. https://deepmind.google/research/